

Práctica 5. Estimación Puntual

Inferencia Estadística 2024-2025

JUAN ELIAS LARA SOTO

Cargue el archivo PRACTICA5.RDS disponible en Campus Virtual usando el siguiente código:

```
datos <- readRDS("PRACTICA5.RDS")
```

Ejercicio 1

Argumente qué distribución o distribuciones de probabilidad podrían haber generado las diez muestras que aparecen como columnas en el `data.frame` nombrado *datos*. (Ver anexo).

```
datos <- read.csv("datos_practica5.csv")  
  
library(ggplot2)  
library(dplyr)
```

Adjuntando el paquete: 'dplyr'

The following objects are masked from 'package:stats':

`filter`, `lag`

The following objects are masked from 'package:base':

`intersect`, `setdiff`, `setequal`, `union`

```
library(MASS)
```

Adjuntando el paquete: 'MASS'

The following object is masked from 'package:dplyr':

select

```
# Función general mejorada
graficar_variable <- function(x, nombre, tipo, params = list()) {
  df <- data.frame(x = x)

  if (tipo == "discreta") {
    x_vals <- if (!is.null(params$valores_posibles)) {
      params$valores_posibles
    } else {
      sort(unique(x))
    }

    tabla_emp <- as.data.frame(table(factor(x, levels = x_vals)))
    colnames(tabla_emp) <- c("x", "Frecuencia")
    tabla_emp$Tipo <- "Empírica"

    if (!is.null(params$dist)) {
      if (params$dist == "binom") {
        probs <- dbinom(as.numeric(as.character(x_vals)), size = params$n, prob = params$p)
      } else if (params$dist == "pois") {
        probs <- dpois(as.numeric(as.character(x_vals)), lambda = params$lambda)
      }
      freqs <- probs * length(x)
      tabla_teo <- data.frame(x = factor(x_vals, levels = x_vals), Frecuencia = freqs, Tipo = "Teórica")
      tabla_plot <- rbind(tabla_emp, tabla_teo)

      p <- ggplot(tabla_plot, aes(x = x, y = Frecuencia, fill = Tipo)) +
        geom_bar(stat = "identity", position = "dodge", alpha = 0.8) +
        scale_fill_manual(values = c("Empírica" = "skyblue", "Teórica" = "red")) +
        labs(title = paste("Histograma de", nombre), x = nombre, y = "Frecuencia", fill = "Tipo")
    } else {
      p <- ggplot(tabla_emp, aes(x = x, y = Frecuencia)) +
        geom_bar(stat = "identity", fill = "skyblue", alpha = 0.8) +
        labs(title = paste("Histograma de", nombre), x = nombre, y = "Frecuencia")
    }
  } else if (tipo == "continua") {
    p <- ggplot(df, aes(x = x)) +
      geom_density(color = "blue", fill = "skyblue", alpha = 0.4, linewidth = 1) +
  }
```

```

labs(title = paste("Densidad de", nombre), x = nombre, y = "Densidad")

if (!is.null(params$dist)) {
  if (params$dist == "unif") {
    # Corrección específica para distribución uniforme
    x_teo <- seq(params$min, params$max, length.out = 200)
    y_teo <- dunif(x_teo, min = params$min, max = params$max)
    df_teo <- data.frame(x = x_teo, y = y_teo)

    p <- p +
      geom_line(data = df_teo, aes(x = x, y = y), color = "red", linewidth = 1) +
      annotate("text", x = params$max, y = max(y_teo),
        label = "Rojo: Teórica\nAzul: Empírica",
        hjust = 1.1, vjust = 2, size = 3.5, color = "black") +
      coord_cartesian(xlim = c(params$min - 0.5, params$max + 0.5))
  } else {
    # Otras continuas: normal, exp, gamma
    x_teo <- seq(min(x), max(x), length.out = 200)
    if (params$dist == "norm") {
      y_teo <- dnorm(x_teo, mean = params$mean, sd = params$sd)
    } else if (params$dist == "exp") {
      y_teo <- dexp(x_teo, rate = params$lambda)
    } else if (params$dist == "gamma") {
      y_teo <- dgamma(x_teo, shape = params$shape, rate = params$rate)
    }
    df_teo <- data.frame(x = x_teo, y = y_teo)

    p <- p +
      geom_line(data = df_teo, aes(x = x, y = y), color = "red", linewidth = 1) +
      annotate("text", x = Inf, y = Inf,
        label = "Rojo: Teórica\nAzul: Empírica",
        hjust = 1.1, vjust = 2, size = 3.5, color = "black")
  }
}


print(p)
}

### Graficar todas


# X_1: Bernoulli

```


```
p1 <- mean(datos$X_1)
graficar_variable(datos$X_1, "X_1", tipo = "discreta", params = list(dist = "binom", n = 1, p = p1))
```




```
# X_2: Poisson
graficar_variable(datos$X_2, "X_2", tipo = "discreta", params = list(dist = "pois", lambda = mean(datos$X_2)))
```




```
# X3: Binomial
n3 <- max(datos$X3)
p3 <- mean(datos$X3) / n3
graficar_variable(datos$X3, "X3", tipo = "discreta", params = list(dist = "binom", n = n3,
```




```
# X_4: Normal
graficar_variable(datos$X_4, "X_4", tipo = "continua", params = list(dist = "norm", mean = m
```




```
# X_5: Exponencial
graficar_variable(datos$X_5, "X_5", tipo = "continua", params = list(dist = "exp", lambda = 1))
```




```
# X_6: Gamma
ajuste_gamma <- fitdistr(datos$X_6, "gamma")
graficar_variable(datos$X_6, "X_6", tipo = "continua", params = list(dist = "gamma", shape = 1, rate = 1))
```




```
# X_8: Uniforme  
graficar_variable(datos$X_8, "X_8", tipo = "continua", params = list(dist = "unif", min = min(datos$X_8), max = max(datos$X_8)))
```




```
# X_9: Normal
graficar_variable(datos$X_9, "X_9", tipo = "continua", params = list(dist = "norm", mean = m
```



```
# X_10: Binomial contaminada (filtramos negativos)
x10 <- datos$X_10[datos$X_10 >= 0]
n10 <- max(x10)
p10 <- mean(x10) / n10
graficar_variable(x10, "X_10 (filtrado)", tipo = "discreta", params = list(dist = "binom", n
```



Ejercicio 2

Sabiendo la familia paramétrica de las distribuciones que generaron los datos, proponga *intuitivamente* algún estimador T (función de la muestra) para aproximar los parámetros de las distribuciones de X_2 , X_3 , X_4 , X_6 , X_8 , X_9 y X_{10}

A continuación, proponemos estimadores T para los parámetros de las siguientes variables, asumiendo conocidas sus distribuciones.

$X_2 \sim \text{Poisson}(\lambda)$

- **Parámetro:** λ
- **Propiedad:** $\mathbb{E}[X] = \lambda$
- **Estimador:**

$$\hat{\lambda} = \bar{X}_2 = \frac{1}{n} \sum_{i=1}^n X_{2i}$$

$$X_3 \sim \mathbf{Binomial}(n, p)$$

- **Parámetro:** p , suponiendo n conocido
- **Propiedad:** $\mathbb{E}[X] = np$
- **Estimador:**

$$\hat{p} = \frac{\bar{X}_3}{n}$$

$$X_4 \sim \mathcal{N}(\mu, \sigma^2)$$

- **Parámetros:** μ, σ^2
- **Estimadores:**

$$\hat{\mu} = \bar{X}_4, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_{4i} - \bar{X}_4)^2$$

$$X_6 \sim \mathbf{Gamma}(\alpha, \lambda)$$

- **Parámetros:** α, λ
- **Propiedades:**

$$\mathbb{E}[X] = \frac{\alpha}{\lambda}, \quad \text{Var}(X) = \frac{\alpha}{\lambda^2}$$

- **Estimadores:**

$$\hat{\lambda} = \frac{\bar{X}_6}{s^2}, \quad \hat{\alpha} = \frac{\bar{X}_6^2}{s^2}$$

$$X_8 \sim \mathcal{U}(a, b)$$

- **Parámetros:** a, b
- **Estimadores:**

$$\hat{a} = \min(X_8), \quad \hat{b} = \max(X_8)$$

$$X_9 \sim \mathcal{N}(\mu, \sigma^2)$$

- **Igual que en X_4 :**

$$\hat{\mu} = \bar{X}_9, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_{9i} - \bar{X}_9)^2$$

$$X_{10} \sim \mathbf{Binomial}(n, p)$$

- **Con valores negativos filtrados**
- **Se estima:** $n = \max(X_{10})$
- **Estimador:**

$$\hat{p} = \frac{\bar{X}_{10}}{n}$$

Ejercicio 3

La variables X_7 y X_4 están relacionadas como sigue:

$$X_7 = \beta_0 + \beta_1 X_4 + \epsilon,$$

siendo $\beta_0, \beta_1 \in \mathbb{R}$ parámetros y $\epsilon \sim N(0, \sigma^2)$.


Proponga una estimación para los parámetros.

```
datos <- read.csv("datos_practica5.csv")

library(ggplot2)

# Crear gráfico de dispersión + recta de regresión lineal
ggplot(datos, aes(x = X_4, y = X_7)) +
  geom_point(color = "steelblue", alpha = 0.6, size = 2) + # nube de puntos
  geom_smooth(method = "lm", color = "red", se = FALSE) + # recta de regresión
  labs(
    title = "Relación entre X_4 y X_7",
    x = "X_4 ",
    y = "X_7 "
  ) +
  theme_minimal()
```

`geom\_smooth()` using formula = 'y ~ x'



Propuesta de estimación:

Estimación de los parámetros

Para estimar los valores de β_0 y β_1 se puede utilizar una **regresión lineal simple**, que es una técnica estadística que permite encontrar la recta que mejor se ajusta a los datos observados de X_4 y X_7 .

Esta recta representa la relación entre ambas variables y se construye de forma que el error total sea el menor posible.

La regresión nos proporciona:

- **El intercepto** ($\hat{\beta}_0$): el valor aproximado de X_7 cuando $X_4 = 0$.
- **La pendiente** ($\hat{\beta}_1$): cuánto cambia X_7 cuando X_4 aumenta una unidad.

Si la pendiente es distinta de cero, eso indica que **sí existe una relación lineal entre X_4 y X_7** .

En resumen, una buena forma de estimar estos parámetros es ajustar un modelo de regresión lineal simple que nos diga cómo se comporta X_7 en función de X_4 .

Anexo

Los datos han sido generados con distribución base:

- $X_1 \sim \text{Binomial}(n, p)$
- $X_2 \sim \text{Poisson}(\lambda)$
- $X_3 \sim \text{Binomial}(n, p)$
- $X_4 \sim \text{Normal}(\mu, \sigma)$
- $X_5 \sim \text{Exponencial}(\lambda)$
- $X_6 \sim \text{Gamma}(\alpha, \lambda)$
- $X_8 \sim \text{Uniforme}(a, b)$
- $X_9 \sim \text{Normal}(\mu, \sigma)$
- $X_{10} \sim \text{Binomial}(n, p).$

Algunas muestras están contaminadas con datos generados fuera de su distribución base.

Quarto

Quarto enables you to weave together content and executable code into a finished document. To learn more about Quarto see <https://quarto.org>.

Running Code

When you click the **Render** button a document will be generated that includes both content and the output of embedded code. You can embed code like this:

```
1 + 1
```

```
[1] 2
```

You can add options to executable code like this

```
[1] 4
```

The `echo: false` option disables the printing of code (only output is displayed).