


## 0. Captura con la gráfica del MSE





### 1. Época de parada

La red debería dejar de entrenarse cuando el error de validación (MSE de validación) alcanza su mínimo y empieza a aumentar, ya que a partir de ese punto el modelo empieza a sobreajustarse (memoriza los datos de entrenamiento y pierde capacidad de generalización).


### 2. Variabilidad de resultados con 2000 épocas

La variabilidad entre ejecuciones se debe a la inicialización aleatoria de los pesos y, en menor medida, a la división aleatoria de los datos entre entrenamiento, validación y test. Al partir de condiciones iniciales distintas, el algoritmo de descenso del gradiente puede converger a mínimos locales diferentes, produciendo curvas de MSE distintas en cada ejecución.



### 3. Rango de la función a aprender (Clasificación/D\_Vertebral\_Column.mat)

El rango de la función objetivo es  $[0, 1]$ , ya que se trata de un problema de clasificación binaria (la red aprende a decidir si un patrón pertenece o no a una clase).



#### 4. ¿Clasificación o regresión?

En este caso la red está realizando una clasificación, ya que las salidas son discretas (0 o 1) y la red intenta separar clases de patrones de entrada.


#### 5. Comparación Beta = 1.0 vs Beta = 0.1

Con Beta = 1.0, la pendiente de la función logística es más pronunciada, por lo que el aprendizaje es más rápido y se alcanza un ECM menor.


Con Beta = 0.1, la función de activación es más plana, lo que provoca actualizaciones más suaves y un aprendizaje más lento, resultando en un ECM mínimo mayor.

La diferencia se debe a la sensibilidad de la función logística: una beta más alta amplifica los cambios y mejora la convergencia.

Beta=0.1:



Beta=1



## 6. Rango de la función a aprender (Regresión/D\_Parkinson\_Telemonit.mat)

El rango de la función es continuo, ya que los valores de salida representan una variable numérica real, no clases discretas.

## 7. ¿Clasificación o regresión (Parkinson)?

En este caso la red realiza una regresión, ya que el objetivo es predecir un valor continuo (una medida médica del Parkinson) a partir de los atributos de entrada.


## 8. Comparación Beta = 1.0 vs Beta = 0.1 (Regresión)

Con Beta = 1.0, la red converge más rápido y obtiene un ECM menor, ya que la activación responde más bruscamente a los errores.

Con Beta = 0.1, el aprendizaje es más lento y la red queda con mayor error residual, porque la función de activación es más “suave”.

La diferencia se debe a la ganancia (pendiente) de la función logística, que controla la sensibilidad de la red frente a los errores.

Beta=1



Beta=0.1

